Bitácora de desarrollo

Proyecto: dashboard del historial extendido de Spotify de Gabriel y Javier. Big Data, octubre de 2026. Cada entrada indica quién la registró: **G** (Gabriel), **J** (Javier) o **GJ** (ambos).

a) Obstáculos encontrados

Fecha	Quién	Obstáculo	Cómo lo resolvimos
12 oct	G	El export viene en varios JSON por persona, mezclados con archivos de video y un PDF.	Leímos solo **Streaming_History_*.json** con unión por nombre de columna; la persona sale del nombre de la carpeta.
12 oct	G	Montar el stack del curso (MinIO, Spark, ClickHouse, Kafka) en Windows: imágenes que no existían, puertos ocupados y pyspark que solo corre con **spark-submit**.	Un script (**levantar.ps1**) que libera puertos, espera a cada servicio y se puede repetir.
25 oct	G	Las horas salían corridas. **ts** está en UTC y marca el fin de la reproducción, y DuckDB lo leía con la zona de la computadora.	Fijamos la sesión en UTC, calculamos el inicio (**ts** menos **ms_played**) y convertimos con la zona del país de conexión.
25 oct	G	La gráfica por mes unía 2017 con 2023 y escondía un hueco de años.	Rellenamos los meses vacíos con cero: los datos continuos de Gabriel empiezan el 14 jul 2023, no en enero.
25 oct	G	Al auditar el informe contra los datos, 8 afirmaciones no cuadraban (por ejemplo, podcasts «en italiano» que eran en inglés, y una canción contada por partes).	Un script (**pipeline/auditoria.py**) recalcula cada cifra y busca su cita en el .docx; corregimos el texto hasta quedar en 66 de 66.
25 oct	GJ	Retomamos el proyecto el mismo día de la entrega del informe.	Recortamos alcance a lo que se califica (insights, dashboard y narrativa) y dejamos Spark y ClickHouse como ruta de escalado.

b) Dudas que surgieron

Duda	Respuesta a la que llegamos
¿**ts** es el inicio o el fin?	El fin, en UTC (lo dice el ReadMe del export).
¿Qué cuenta como escuchar una canción?	30 s o más, como Spotify. El histograma de duración muestra dos grupos que esa regla separa.
¿Skip es **skipped** o **reason_end = fwdbtn**?	**skipped**: vale 97 a 98% en los botones de saltar y 0% en el resto.
¿Cómo comparamos historiales de distinto largo y volumen?	Con una ventana común (desde jul 2023) y en porcentaje del tiempo propio.
¿Es justo decir quién llegó primero a un artista?	Solo contando artistas que ambos empezaron después del inicio común y con más de 30 días de diferencia. Aun así lo reportamos con su sesgo.

c) Decisiones tomadas y su justificación

Decisión	Por qué
Eliminar la IP en el primer paso	Es dato personal y no responde ninguna pregunta.
DuckDB como motor principal en vez de Spark y ClickHouse	81 mil filas (unos 60 MB) se procesan en menos de 2 s en una laptop. Elegir la herramienta por el volumen real es más honesto que forzar un cluster.

Decisión	Por qué
Verde y negro como Spotify, con un color fijo por persona (Gabriel verde, Javier blanco en tema oscuro y negro en claro)	La persona se reconoce igual en todas las gráficas y no cambia al filtrar; el verde contra blanco o negro se distingue por luminosidad, también con daltonismo.
Heatmaps separados, cada uno en % del tiempo propio	En una escala absoluta, el volumen de Gabriel taparía el patrón de Javier.
Barras y líneas; sin pasteles	Longitud y posición se comparan mejor que los ángulos.
Dashboard estático (HTML con los datos embebidos)	Se abre con doble clic en la computadora del salón, sin servidor ni Docker.
Una canción = nombre + artista, no su URI	La versión single y la del álbum tienen URIs distintas; contarlas aparte partía el conteo (498 canciones).
El último mes se marca como incompleto	Los datos terminan a media mes; sin marcarlo parecía una caída.

d) Aprendizajes obtenidos

- La mayor parte del trabajo fue entender el export, no graficar. Cada regla de limpieza salió de una gráfica exploratoria.
- Las fechas son la trampa principal: UTC contra hora local, inicio contra fin y la zona por defecto de la herramienta.
- Una línea sin los meses vacíos miente; rellenar con ceros reveló el problema de cobertura.
- Comparar personas exige una ventana común y medidas relativas; si no, gana quien tiene más datos.
- Un texto escrito a mano se desfasa de los datos: verificar cada cifra con un script encontró errores que una lectura no vio.
- Un export de música revela viajes con fecha, la rutina diaria y hasta lo que se escuchó en modo privado.
- Las mismas preguntas (cuándo, qué tan denso, qué tan poco) sirven para cualquier red social; solo cambia la unidad de interacción.